

深度学习

一、填空题

1、什么叫反向传播（了解它的机制、原理）。

反向传播的核心是一种高效计算复合函数梯度的算法，它通过链式法则将最终输出层的误差（损失）反向逐层传播，以计算网络中每个参数（权重和偏置）对于总误差的“贡献度”（即梯度），从而指导参数更新。

【填空题预测】

- ① 反向传播的机制可概括为前向传播、反向传播、参数更新。
- ② 反向传播算法中，误差信号从输出层向输入层传递，通过链式法则计算梯度。
- ③ 反向传播中，激活函数的导数作用是引入非线性，若导数接近零会导致梯度消失问题。
- ④ 反向传播是一种高效计算复合函数梯度的算法，它通过链式法则将最终输出层的误差反向逐层传播，以计算网络中每个参数对于总误差的“贡献度”，从而指导参数更新。

2、激活函数有哪些、其作用分别是什么、适用于哪些类型的任务？

（1）激活函数

- ① 定义：激活函数是神经网络中，对神经元的加权输入进行非线性变换并产生输出的函数。
- ② 主要作用：
 - a、引入非线性，使神经网络可以逼近任何复杂的函数，成为“通用函数逼近器”。
 - b、决定神经元是否被激活，根据输入信号的重要性，决定是否传递以及传递多大的信号给下一层。
 - c、将输出映射到特定范围，如 Sigmoid 函数将输出映射到(0,1)，便于表示概率。

（2）常用激活函数

- ① **Sigmoid**：输出 0~1，用于二分类输出层，易导致梯度消失。
- ② **Tanh**：输出 -1~1，以 0 为中心，常用于 RNN。
- ③ **ReLU**：最常用隐藏层函数，计算快 $f(x)=\max(0,x)$ ，但可能导致神经元“死亡”。
- ④ **Softmax**：用于多分类输出层，将输出转为概率分布。

【填空题预测】

- ① 列举常用的激活函数：**Sigmoid**、**Tanh**、**ReLU**、**Softmax**
- ② 多分类任务输出层通常使用 **Softmax** 激活函数，在 Transformer 中，BERT 隐藏层默认使用的激活函数是 **GELU**。

③ 【口诀】

分类输出 Softmax，概率 Sigmoid；
隐藏 ReLU 快又省，死亡负区 Leaky 补；
零均值找 Tanh，精度爆表上 ELU；
BERT 爱 GELU，Swish 自门控更深渡。

3、了解一下反向传播

反向传播是深度学习中训练神经网络的核心算法：它从网络的输出层开始，根据预测值与真实标签的误差，沿着与前向传播相反的方向，利用链式法则逐层计算每个参数（权重、偏置）对误差的梯度，最终通过梯度下降法更新这些参数，从而让网络的预测结果不断逼近真实值。

【填空题预测】

①在 RNN 的反向传播中，由于参数共享，梯度需在时间方向展开计算，这种现象称为 **BPTT**，可能导致梯度消失或梯度爆炸。

4、了解一下卷积操作、卷积核、参数共享（比如参数共享是基于什么实现的）

卷积操作：一种特殊的数学运算，在 CNN 中特指两个函数（如图像和卷积核）之间进行点积求和的运算过程。在 CNN 中的机制：将一个小的卷积核（过滤器）在输入数据（如图像）上滑动（从左到右，从上到下）。在每一个位置，将卷积核与输入数据对应的局部区域进行逐元素相乘。将所有乘积结果求和，得到一个单一的数值，作为输出特征图上该位置的特征值。

卷积核：也叫滤波器，是一个权重矩阵（通常是 $3 \times 3, 5 \times 5$ 等小尺寸）。作用是提取特定类型的局部特征。不同的卷积核负责检测不同的特征（如第一个核检测垂直边缘，第二个核检测水平边缘，更深层的核检测更复杂的图案如车轮、眼睛）。

参数共享：同一个卷积核在其滑过的整个输入区域上使用相同的权重（参数）。

如何实现：一个卷积核只有一组固定的权重（例如一个 $3 \times 3 \times 3$ 的核，只有 27 个参数）。无论这个核滑动到图像的左上角还是右下角，都使用这一组 27 个参数与当地的图像块进行计算。因此，这组参数在整个输入空间上是共享的。

基于什么实现：参数共享是基于“平移不变性”的假设实现的。即我们认为一个有用的特征（如“边缘”），无论它出现在图像的哪个位置，都应该由相同的特征探测器（同一个卷积核）来识别。一只猫的耳朵在左边还是右边，都应该被识别为“耳朵”。

【填空题预测】

- ①卷积神经网络参数少的主要原因之一是使用了参数共享技术。
- ②参数共享是基于平移不变性实现的
- ③参数共享是指同一个卷积核在所有空间位置上复用同一组权重，从而把参数量从像素级降到核权重级。

5、RNN 的变型 LSTM 是什么、GRU 是什么？

LSTM 是长短期记忆网络，是 RNN 的一种复杂变体，通过精心设计的遗忘门、输入门、更新细胞状态、输出门的结构来有选择地记住重要信息、忘记不重要信息。

GRU 是门控循环单元，是 LSTM 的一种简化、高效的变体。它将 LSTM 的三个门合并为两个，分别为重置门和更新门，并将细胞状态和隐藏状态合并。

【填空题预测】

- ①LSTM 和 GRU 都是为了解决传统 RNN 的梯度消失/梯度爆炸（或长距离依赖）问题而提出的。它们通过引入门控机制来控制信息流。
- ②LSTM 单元包含三个门：遗忘门、输入门 和 输出门，以及一个细胞状态。
- ③GRU 单元包含两个门：更新门 和 重置门。
- ④在 LSTM 中，负责长期记忆传递的核心路径是 细胞状态 (C_t)。

6、什么是过拟合和欠拟合，有什么异同

欠拟合：模型过于简单，无法捕捉数据中的基本规律和特征。无论是在训练数据还是新数据上，表现都很差。

原因：

- ①模型复杂度太低。
- ②特征太少或信息不足。
- ③训练不充分。

解决方法：

- ①增加模型复杂度。
- ②增加更多有效特征。
- ③延长训练时间。

过拟合：模型过于复杂，不仅学习了数据中的普遍规律，还“死记硬背”了训练数据中的噪声和随机波动。导致在训练数据上表现极好，但在新数据上表现糟糕。

原因：

- ①模型复杂度过高。
- ②训练数据量太少。
- ③训练时间过长。

总之，过拟合是模型太复杂，欠拟合是模型太简单，都是**模型性能不佳**的表现，是**模型能力与数据复杂度不匹配**的结果。

【填空题预测】

- ①模型过于简单，无法捕捉数据基本特征，导致训练和测试误差都很高的现象称为欠拟合。
- ②模型在训练集上表现很好，但在测试集上表现很差的现象称为过拟合。
- ③欠拟合时，训练误差高，测试误差高。
- ④过拟合时，训练误差低，测试误差高。
- ⑤当模型出现高偏差时，通常意味着欠拟合；出现高方差时，通常意味着过拟合。
- ⑥解决欠拟合的常用方法是增加模型复杂度。
- ⑦解决过拟合的常用方法有正则化、增加训练数据、Dropout、早停 等。
- ⑧在神经网络中，随机丢弃一部分神经元来防止过拟合的技术叫做Dropout。

7、BERT 模型

BERT 模型是基于 Transformer 的双向编码器表示。核心本质：一个预训练语

言模型。它不是为某个具体任务设计的，而是通过在海量无标注文本上学习通用的语言表示，然后可以轻松地微调到各种下游 NLP 任务上。只使用了 Transformer 的编码器部分（没有解码器）。利用了自注意力机制，能高效捕捉长距离依赖。

【填空题预测】

- ①BERT 的核心创新在于其双向的上下文编码能力。
- ②BERT 的两个预训练任务是掩码语言模型和下一句预测。
- ③在 MLM 任务中，BERT 会随机掩盖输入中15%的词汇进行预测。
- ④BERT 的提出，标志着 NLP 进入了预训练语言模型时代。
- ⑤相比于单向语言模型（如 GPT），BERT 的优势在于能够更好地理解词语的上下文语境。

8、卷积层和池化层的作用

卷积层是 CNN 的核心特征提取器，负责从输入数据中自动学习并识别有意义的局部特征模式。

主要作用：

- ①特征提取
- ②参数共享与稀疏连接
- ③保留空间拓扑结构
- ④平移不变性

池化层是卷积层的辅助层，负责对特征图进行下采样，以压缩数据和增强特征的鲁棒性。

主要作用：

- ①降维与减少计算量
- ②引入平移、旋转和尺度鲁棒性（不变性）
- ③防止过拟合
- ④扩大感受野

【填空题预测】

- ①卷积神经网络中，卷积层的主要作用是特征提取；池化层的主要作用是降维（或下采样）和增强特征的平移不变性（或鲁棒性）。
- ②使用池化层可以有效地减少模型的参数量和计算量。
- ③最常见的池化操作是最大池化和平均池化。

9、什么是多模态

多模态也称多模态人工智能，指的是能够同时处理、理解和生成来自多种不同模态信息的 AI 系统或模型。

模态：信息的存在形式或类型。就像人类通过五种感官（视觉、听觉、触觉、嗅觉、味觉）感知世界一样，在 AI 中，模态指代不同类型的数据源。

核心思想：融合与协同。让 AI 模仿人类，综合利用多种信息源（如图像、文字、声音、视频、传感器数据等）进行综合决策和创造，而不是孤立地处理单一类型数据。

常见模态举例：

- ①文本：自然语言（文章、对话、指令）
- ②视觉：图像、视频、图表、动态画面
- ③听觉：语音、音乐、环境声音

【填空题预测】

- ①能够处理和理解多种不同类型数据（如图像、文本、语音）的 AI 技术被称为多模态人工智能（或多模态学习）。
- ②多模态学习的核心目标是实现不同模态信息之间的对齐（或融合/协同）。
- ③将图像和文本映射到同一语义空间进行对比学习的著名模型是CLIP。
- ④与单模态模型相比，多模态模型能提供更丰富、鲁棒、准确的理解和生成能力。
- ⑤多模态学习面临的主要挑战之一是如何弥合不同模态数据之间的语义鸿沟（或异构鸿沟）。

10、什么叫小样本学习

(1) 小样本学习：是机器学习的一个子领域，其目标是让模型在仅使用极少量（通常每个类别只有 1-10 个）有标签样本进行训练后，就能快速识别和学习新类别或新任务。传统的深度学习模型是“数据饥渴”型的，需要海量标注数据才能表现良好。但在现实世界中，为每个新任务收集大量标注数据往往成本高昂、耗时费力，甚至不可能（如医疗罕见病图像识别、定制化工业缺陷检测）。FSL 旨在解决这一矛盾。

(2) 核心思想：学会“学习”。FSL 不是让模型直接记住大量具体的特征，而是让模型学会一种“元能力”——如何根据少量示例，快速归纳出新概念或新任务的本质。这类似于人类“举一反三”的能力。

(3) 核心范式：N-way K-shot 这是评估 FSL 模型的经典设置。

- ①**N-way**：任务中有 N 个新类别（模型在训练阶段从未见过这些类别的样本）。
- ②**K-shot**：对于这 N 个新类别，每个类别只提供 K 个有标签的支持样本供模型学习。
- ③**Query**：然后提供一批查询样本，让模型判断它们属于 N 个类别中的哪一个。

(4) 代表模型：①孪生网络、②匹配网络、③原型网络。

(5) 应用场景：

- ①**图像识别**：识别稀有动物、特定型号的工业零件、个性化用户物品。
- ②**自然语言处理**：进行新意图分类、特定领域命名实体识别（如法律、医疗文本）。

【填空题预测】

- ①旨在让模型仅通过极少量样本就能学习新任务的机器学习范式称为小样本学习。
- ②小样本学习要解决的核心问题是数据稀缺（或标注成本高）。
- ③在小样本学习中，常用的评估设置是N-way K-shot 任务。

二、简答题（已经精简，保留了核心内容，直接背）

1、什么是监督学习、什么是无监督学习

(1) 监督学习

- ①**定义:** 监督学习是训练数据含明确“正确答案”标签的机器学习方法，模型通过学习输入数据与输出标签的映射关系实现预测或分类。
- ②**数据形式:** 训练数据为{输入特征，输出标签}的配对数据。
- ③**主要任务:**
 - a、**分类:** 预测离散类别标签；
 - b、**回归:** 预测连续数值。
- ④**典型算法:** 线性回归、逻辑回归、决策树、随机森林、支持向量机（SVM）、CNN 等深度学习网络。

(2) 无监督学习

- ①**定义:** 无监督学习是训练数据无预先标签的机器学习方法，模型需自主发现数据隐藏的结构、模式或分布。
- ②**数据形式:** 训练数据仅含{输入特征}，无对应输出标签。
- ③**主要任务:**
 - a、**聚类:** 将数据分相似组；
 - b、**降维:** 保留关键信息减少特征数量；
 - c、**关联规则学习:** 发现数据项目关联。
- ④**典型算法:** K-均值聚类、层次聚类、主成分分析（PCA）、自编码器、GAN 的生成器训练过程。

2、什么叫激活函数、常用的几个激活函数

(1) 激活函数

- ①**定义:** 激活函数是神经网络中，对神经元的加权输入进行非线性变换并产生输出的函数。
- ②**主要作用:**
 - a、引入非线性，使神经网络可以逼近任何复杂的函数，成为“通用函数逼近器”。
 - b、决定神经元是否被激活，根据输入信号的重要性，决定是否传递以及传递多大的信号给下一层。
 - c、将输出映射到特定范围，如 Sigmoid 函数将输出映射到(0,1)，便于表示概率。

(2) 常用激活函数

- ①**Sigmoid:** 输出 0~1，用于二分类输出层，易导致梯度消失。
- ②**Tanh:** 输出-1~1，以 0 为中心，常用于 RNN。
- ③**ReLU:** 最常用隐藏层函数，计算快 $f(x)=\max(0,x)$ ，但可能导致神经元“死亡”。
- ④**Softmax:** 用于多分类输出层，将输出转为概率分布。

3、什么是学习率、分哪几种类型、作用分别是什么？

(1) 学习率 (Learning Rate)

学习率是深度学习中最重要的超参数之一，用于控制模型在每次参数更新时的步长大小。它决定了在优化过程中（如梯度下降），模型根据损失函数的梯度来调整参数的幅度。

(2) 学习率的类型：

- ①**固定学习率**: 是在训练中保持恒定，优点是简单易用，缺点是难以适配不同训练阶段需求，易导致收敛慢或震荡。
- ②**周期性学习率**: 是在一定范围内周期性波动，能帮助模型跳出局部最优、加速。
- ③**自适应学习率**: 是基于梯度历史信息自动调整，常见 AdaGrad、RMSProp 等优化器，可减少超参数调优负担并适配不同参数特性。

(3) 学习率的主要作用:

- ①**控制收敛速度**: 学习率过小会导致收敛慢、训练时间长；学习率过大可能会导致震荡、不收敛或越过最优解。
- ②**影响模型性能**: 合适的学习率有助于找到更优的局部最小点或全局最小点，提升模型精度。
- ③**平衡探索与收敛**: 自适应学习率等方法可在训练早期快速探索参数空间，后期精细调优。

4、深度学习中怎么处理过拟合问题

过拟合: 过拟合是指模型在训练数据上表现极佳，但在未见过的测试数据上表现显著下降的现象，本质是模型过度学习了训练数据中的噪声和个别样本的特有模式，而非数据的通用规律。

可以通过下面几个层面来解决过拟合问题：

(1) 数据层面

- ①增加训练数据：最根本有效方式
- ②数据增强：对现有数据变换（如图像旋转、文本同义词替换）生成“新”样本

(2) 模型层面

- ①简化模型：减少网络层数、神经元数量降低复杂度
- ②正则化：L1（稀疏权重）、L2（平滑权重，常用）
- ③Dropout：训练时随机丢弃部分神经元，抑制协同适应
- ④早停：监控验证集性能，停止于泛化最优状态

(3) 训练策略层面

- ①适中批量大小：平衡训练稳定性与泛化性
- ②合适优化器与学习率策略：如 Adam、学习率衰减

5、CNN、RNN 分别适用于什么场景

(1) CNN (卷积神经网络)

①核心特性：

- a、具有局部感受野和权值共享机制，能有效提取输入数据的空间特征。
- b、对数据的平移、缩放、旋转具有一定的不变性。
- c、通过池化操作实现特征降维，减少计算量。

②适用场景：

- a、**计算机视觉领域**: 图像分类、目标检测、语义分割、人脸识别等。
- b、**具有空间结构的非图像数据**: 文本分类、音频信号处理、遥感图像分析等。

(2) RNN (循环神经网络)

①核心特性：

- a、具有循环连接结构，能够处理序列数据，并利用隐藏层状态保存历史信息。
- b、对输入数据的顺序高度敏感，适合捕捉序列中的时序依赖关系。
- c、传统 RNN 存在梯度消失或梯度爆炸问题，改进型（LSTM、GRU）可缓解该问题。

②适用场景：

- a、自然语言处理领域：文本生成、机器翻译、情感分析、语音识别等。
- b、时序数据处理：时间序列预测、视频帧序列分析、行为识别等。

6、GAN 模型原理、作用、架构

(1) GAN (生成对抗网络, Generative Adversarial Networks)

①原理：

- a、GAN 的核心是对抗学习思想，通过两个网络的相互博弈、交替训练来实现生成模型的优化。
- b、生成器尝试生成尽可能真实的假数据，以欺骗判别器；判别器则尝试准确区分真实数据与生成的假数据。
- c、最终达到纳什均衡：生成器生成的假数据与真实数据无差异，判别器无法区分，对任何输入的判断概率均为 0.5。

②作用：

- a、**数据生成**：生成高质量的逼真数据，如自然图像、文本、音频、视频等，可用于扩充训练数据集。
- b、**图像编辑与转换**：实现图像风格迁移、超分辨率重建、图像修复、人脸生成与编辑等计算机视觉任务。
- c、**无监督/半监督学习**：在缺乏大量标注数据的场景下，利用对抗学习完成特征提取与任务训练，提升模型性能。

(2) GAN 的架构

①基本组成：由生成器（G）和判别器（D）两个独立深度子网络构成。

- a. **生成器（G）**：输入随机噪声向量，输出与真实数据同分布的假数据，目标是最大化判别器的判断错误率。
- b. **判别器（D）**：输入真实/假数据，输出 0~1 的真实置信度概率，目标是最小化真假数据的判断误差。

②训练流程：

- a. 固定 G，训练 D：使真实数据输出趋近 1，假数据输出趋近 0，更新 D 参数。
- b. 固定 D，训练 G：使生成的假数据经 D 判断的输出趋近 1，更新 G 参数。
- c. 交替重复 a、b 两步，直至达到纳什均衡。

7、自注意力机制 Self-attention 的原理、架构

(1) 自注意力机制 (Self-attention)

①原理：

- a、序列中每个元素与所有元素计算关联权重。
- b、加权求和得到该位置新表示，实现长距离依赖捕捉。
- c、无循环/卷积结构，支持并行计算，解决 RNN 的核心缺陷。

②作用：

- a、捕捉序列任意位置的依赖关系，不受长度限制。

b、为不同位置信息分配权重，突出重要信息，抑制无关信息。

c、Transformer 架构核心组件，支撑 BERT、GPT 等大模型。

(2) 自注意力机制的架构

①**基本组成**：由查询向量（Q）、键向量（K）、值向量（V）构成；三者均为输入序列通过不同可学习权重矩阵线性变换得到。

②**计算流程**：

a、输入序列线性变换，生成 Q、K、V 三个向量矩阵。

b、计算 Q 与 K 的点积得到注意力得分矩阵，缩放后避免梯度爆炸。

c、对得分矩阵应用 Softmax 函数，得到归一化注意力权重矩阵。

d、权重矩阵与 V 矩阵相乘，输出自注意力计算结果。

8、预训练模型 Pre-trained model 的原理、方法

(1) 预训练模型 (Pre-trained model)

①**原理**：

a、基于迁移学习，分预训练和微调两个阶段。

b、在大规模通用无标注/弱标注数据集上训练，学习通用特征表示。

c、迁移预训练参数至下游任务，少量标注数据微调即可完成适配。

②**作用**：

a、解决下游任务标注数据不足问题，提升模型性能。

b、避免从头训练，大幅减少计算资源消耗与训练时间。

c、通用特征泛化能力更强，提升模型鲁棒性。

(2) 预训练模型的方法

①**预训练阶段**：

a、**自监督学习**：最常用方法，构造伪标签实现无监督训练，如 BERT 的掩码语言模型（MLM）、GPT 的自回归语言模型（AR）、对比学习。

b、**有监督预训练**：在大规模有标注数据集上训练，适用于特定领域基础模型。

②**微调阶段**：

a、**全参数微调**：冻结部分底层参数，微调上层及新增任务头的所有参数。

b、**参数高效微调 (PEFT)**：仅微调少量新增参数（如 Adapter、LoRA），保留大部分预训练参数，适用于资源受限场景。

9、迁移学习 Transfer learning 的原理、方法

(1) 迁移学习 (Transferlearning)

①**原理**：

a、核心知识迁移，将源任务通用知识/特征迁移至目标任务。

b、利用任务相似性，解决目标任务数据少、训练难问题。

c、避免从头训练，高效建模提性能。

②**作用**：

a、缓解数据稀缺/标注成本高问题。

b、降计算消耗，加快收敛。

c、提升泛化能力，减少过拟合。

(2) 迁移学习的方法

①**按迁移方式分类**：

a、基于参数的迁移: 复用源模型参数，目标任务微调（如预训练微调、参数冻结）。

b、基于特征的迁移: 源模型作特征提取器，训练新分类器（如固定 CNN 卷积层）。

c、基于实例的迁移: 相似源实例加权参与目标任务训练。

②按迁移场景分类：

a、归纳式: 源-目标任务不同，迁移辅助学习。

b、直推式: 源-目标任务相同，数据分布不同，迁移数据知识。

10、终身学习（Life long Learning）的原理、方法

（1）终身学习（Life long Learning）

①原理：

a、核心持续学习，逐次学多任务且保留旧任务知识。

b、模拟人类学习，解决灾难性遗忘问题。

c、实现知识累积与增量更新，无需从头训练。

②作用：

a、解决灾难性遗忘，避免新任务学习后旧任务性能骤降。

b、支持增量任务学习，适配动态真实场景。

c、实现知识高效复用累积，提升长期学习能力。

（2）终身学习的方法

①基于正则化的方法：

a、新任务训练时，对旧任务重要参数加正则化约束，限制更新幅度。

b、典型：弹性权重整合（EWC）、在线 EWC。

②基于记忆的方法：

a、保存旧任务关键样本 / 特征，新任务训练时周期性重放。

b、典型：经验重放、生成式重放。

③基于架构的方法：

a、动态扩展网络架构，为新任务分配专用子网络，不影响旧任务参数。

b、典型：渐进式网络、模块化网络。

三、论述题

1、Transformer 模型的架构（Attention is All You Need）

Transformer 模型最早由谷歌团队在 2017 年发表的论文《Attention is All You Need》提到，彻底改变了自然语言处理乃至整个深度学习领域的发展轨迹。

（1）Transformer 核心特性

①原理：完全基于自注意力机制+前馈神经网络，摒弃循环/卷积结构。

②优势：支持并行计算，高效捕捉长距离依赖，是 BERT、GPT 等大模型的基础架构。

（2）Transformer 的整体架构

①基本组成：编码器-解码器双层结构，各由 N 个相同子层堆叠（原论文 N=6）。

②输入输出：输入为源/目标序列的嵌入表示+位置编码，输出为目标序列的概率分布。

（3）编码器（Encoder）结构

①单层组成：2 个子层（各接残差连接+层归一化）

a. 多头自注意力层：对源序列多视角自注意力计算，捕捉内部依赖。

b. 位置前馈神经网络（FFN）：对每个位置特征独立非线性变换。

②整体特性：各子层输入输出维度一致，双向捕捉源序列上下文信息。

（4）解码器（Decoder）结构

①单层组成：3个子层（各接残差连接+层归一化）

a. 掩码多头自注意力层：对目标序列自注意力计算，掩码防止看到未来位置，保证自回归。

b. 编码器-解码器注意力层：解码器输出为 Query，编码器输出为 Key/Value，实现注意力对齐。

c. 位置前馈神经网络：与编码器 FFN 结构相同。

2、什么叫机器翻译

（1）机器翻译（Machine Translation, MT）

①定义：

a、是自然语言处理（NLP）的核心任务之一。

b、指利用计算机程序或模型，将一种自然语言（源语言）的文本或语音，自动转换为另一种自然语言（目标语言）的过程。

c、转换过程需保证语义的准确性与表达的流畅性。

②核心作用：

a、突破语言壁垒，实现跨语言的信息快速传递。

b、降低人工翻译的时间成本与人力成本，提升翻译效率。

c、支撑跨语言检索、国际交流、跨境业务等多场景的应用落地。

（2）机器翻译的主要类型

①基于规则的机器翻译（RBMT）：依赖人工制定的语法、词汇转换规则，适应性差。

②基于统计的机器翻译（SMT）：利用大规模平行语料的统计规律建模，性能优于规则型。

③神经机器翻译（NMT）：基于深度学习模型（如 Transformer、RNN），是当前主流方法，翻译质量最高。

3、绿野侦探：植物病害检测项目简介

本项目针对传统植物病害人工诊断效率低、滞后性强的痛点，借助深度学习技术实现作物病害精准快速识别，助力农户早期防治、减少减产损失。

项目依托天池“绿野侦探”赛题，采用 Kaggle 大规模数据集，涵盖 14 种农作物的 26 种病害及健康状态，含 70295 张训练图和 17572 张专家标注验证图。针对传统轻量 CNN 模型不足，我们优化骨干网络为 ImageNet-1k 预训练的 EfficientNet-B3，引入 FPN 多尺度融合与 SE-block 注意力模块，搭配分类别、分场景、分阶段数据增强策略。

实验显示，改进模型在 RTX 5090 和 A6000 环境下验证集准确率达 99.72% 和 99.80%，公开测试集准确率最高 99.8%。模型仅 25.14MB，训练约 43.5 分钟，适配边缘设备秒级诊断，有效解决传统诊断痛点，为粮食安全与智慧农业提供技术支撑。